

个人问答助手 - 评测报告

生成时间：2026-04-24 11:48:01；实验：MVP 实验运行；模式：external_api

项目摘要

项目 ID	proj_b5
项目背景	这个是
被评测系统	是一个
评测目标	重点需
业务规则摘要	
上传材料	jonaslu
题型说明	

实验配置

样本数	20	成功率	0.85
平均总分	0.6368	平均延迟(ms)	21436.22
估算成本	0.0	评分版本	mvp-v1

总体指标

指标	平均分	图示
completeness	0.71	
context_precision	0.25	
context_recall	0.4	
context_relevance	0.62	
correctness	0.65	
evidence_coverage	0.77	
faithfulness	0.7667	
hallucination_risk	0.0833	

hit_rate	0.62	
relevance	0.815	

题型分布

题型	数量
面试问题	9
技术问题	7
职业问题	2
软技能问题	1
业务问题	1

代表性失败案例

问题	系统答	总分	失败标签	裁判理由
你为什么选择数据科学方向？	我选择数据科学方向，主要是因为两个层面的兴趣驱动和能力结合。本科阶段我学的是网络与通信工程和计算机科学，打下了扎实的编程、系统架构和数据库基础，那时候我对所以，在硕士阶段，我主动转向了数据科学方向，在法国里昂第一大学深入学习了机器学习、统计建模、数据科学。简单来说，我选择数据科学，是因为它既满足了我对技术实现的热情，又让我能深入挖掘数据背后的意义，用数据驱动决策。	0.35	['cannot_judge']	RAGAS 算法评分（LLM 逐步推理）
你如何优化 RAG 检索效果？	我在优化RAG检索效果时，主要从**混合召回策略**和**轻量级排序优化**两个方面入手，LLM具体做了这些实践：1. **混合召回策略（向量+关键词）**：最初我只用FAISS做纯向量语义检索，但发现中文场景下对**人名、技术术语、项目名**这类精确匹配内容效果不佳。2. **轻量级融合排序**：考虑到实际部署的资源限制，我没有直接上重型reranker，而是设计了一套轻量级的融合逻辑：将向量召回和关键词召回的结果进行初步融合，再用轻量级模型（如BM25+TF-IDF）进行二次排序。这种方案在个人知识库项目和反欺诈邮件检测系统中都验证过效果——前者让用户能更精准地问到简历或项目经验，后者则提高了可疑邮件的检出率。	0.6	['cannot_judge']	RAGAS 算法评分（LLM 逐步推理）
你的核心技术栈是什么？		0.0	['cannot_judge']	答案为空或请求失败。
这个多 Agent 项目最大的技术亮点是什么？		0.0	['cannot_judge']	答案为空或请求失败。
你如何把分类模型和 RAG 结合？	我在反欺诈邮件检测项目里实践过如何把分类模型和RAG结合起来，这是RAG算法典型的“判断+解释”组合。具体来说，当用户输入一封邮件后，系统首先会调用一个文本分类模型逐步推理判断这封邮件是否有潜在的欺诈风险。如果初步判断为高风险，系统会触发RAG检索，从知识库中拉取相关的邮件样本、规则文档和专家报告。最后，大语言模型会把原始邮件内容、分类模型的输出结果以及RAG检索到的相关证据整合在一起，生成一份详细的分析报告。这个组合不仅用在反欺诈场景，在需要“快速判断+深度解释”的业务中都可以复用。而且在这个项目里我还探索了模型蒸馏和知识图谱的应用。所以总结来说，分类模型和RAG的结合，本质上是用分类做高效决策，用RAG做精准上下文补充，两者互补，提升了系统的可解释性和决策质量。	0.7	['cannot_judge']	RAGAS 算法评分（LLM 逐步推理）
你做过什么 AI 项目？		0.0	['cannot_judge']	答案为空或请求失败。

对比结论

当前报告未选择对比实验。建议至少选择两个实验运行，结合平均总分、失败分布、延迟和成本进行判断。